



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 1

Perceptrón Multicapa

Redes Neuronales

Grupo X

Integrante	LU	Correo electrónico
Bonet, Felipe	668/08	fpbonet@gmail.com
Martínez, Federico	XXX/XX	fedomartinez@hotmail.com
Avendano, Demian	XXX/XX	demian.avendano@gmail.com

Reservado para la cátedra

Instancia	Docente	Nota
Primera entrega		
Segunda entrega		



Facultad de Ciencias Exactas y Naturales Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

Índice

1. Introducción	3
1.1. Introducción al problema	3
1.2. Entrega	3
1.3. Requerimientos	3
1.4. Modo de uso y opciones	3
1.4.1. Opciones	3
2. Desarrollo	5
2.1. Decisiones tomadas y su justificación.	5
2.2. Ejercicio 1	6
2.2.1. Variación del número de capas ocultas.	6
2.2.2. Variación del número de neuronas ocultas.	7
2.2.3. Performance de la red, con entrenamiento sin momentum y con momentum.	8
2.2.4. Performance de la red, con entrenamiento sin y con parámetros adaptativos.	8
2.2.5. Performance de la red, con entrenamiento estocástico, batch y mini-batch.	8
2.2.6. Performance de la red, variando simultáneamente el factor de aprendizaje μ , y el parámetro α del momentum.	8
2.2.7. Performance de la red, con distintas técnicas de inicialización de los pesos de la red.	8
2.2.8. Performance de la red, sin y con preprocesamiento de los patrones.	8
2.2.9. Performance de la red, sin y con early-stopping.	8
2.2.10. Performance de la red, variando las funciones de activación y/o sus parámetros.	8
2.3. Descripción, justificación y performance, de la solución óptima propuesta.	8
2.4. Conclusiones.	8
3. Apéndice - Código	9
4. Bibliografía	10

1. Introducción

En este documento se realizan las actividades propuestas en el TP 1, actividades relacionadas con la implementación de una red neuronal feedforward multicapa, con el fin de lograr predicciones sobre un set de datos, mientras se estudia su comportamiento durante el entrenamiento, en el contexto de un paradigma de aprendizaje supervisado.

1.1. Introducción al problema

Las redes neuronales son modelos computacionales, en los que se intenta emular el funcionamiento fisiológico de un conjunto de neuronas biológicas, interconectadas, con el fin de lograr predicciones a partir de un conjunto de datos similares, presentados previamente. Para ello se modelan, en cada unidad de procesamiento, características que tienen que ver con las condiciones de propagación de señales electroquímicas. Estas condiciones se describen y modelan a partir de observaciones de sobre cómo es transmitida información entre una neurona y otra (o sobre si), y sobre como se encuentran interconectadas.

La suma de las interacciones entre estas unidades modeladas en una topología dada, genera propiedades emergentes que permiten resolver cierto tipos de problemas (caracterizados por el *Teorema de la Aproximación Universal*). Para intentar resolver estos problemas utilizando una red neuronal, es necesario recurrir a diversas técnicas para el ajuste de las variables de la red, y en muchos casos se requiere un paso de preprocesamiento de los datos.

Se implemento una red neuronal multicapa para la predicción de dos set de datos: el primer set, tiene que ver con el diagnóstico de cancer de mamás, los datos de entrada son valores reales, mientras que el dato de salida es la presencia o no de la enfermedad; el segundo set de datos tiene que ver con la eficiencia energética de la regulación de la temperatura de un edificio, los valores de entrada son tanto enteros como reales, existen dos valores de salida reales, que tienen que ver con la carga de calefacción y de refrigeración.

1.2. Entrega

1.3. Requerimientos

- Intérprete python 2.7.
- Librerías estandar, y librería *numpy*.
- Archivo csv con uno de los dos formatos propuestos en el tp.

1.4. Modo de uso y opciones

Para usar este programa, se deben posicionar los archivos csv requeridos, junto a los archivos del programa, el programa se ejecuta desde python 2.7 :

```
$python script.py N args
```

donde N es el número de ejercicio y **args** son los argumentos optativos.

1.4.1. Opciones

- ep**: Cantidad de epocas por default, 500.
- eta**: Tasa de aprendizaje, por default $\eta = 0.05$
- capas**: Capas ocultas de la red, cada numero separado por una coma representa una capa y cada magnitud de la capa representa el numero de neuronas de esa capa, por default = '10,10', o sea, dos capas de 10 neuronas cada una.
- tr**: Cantidad en % del total de datos utilizado para entrenar a la red, por default = 70.
- te**: Cantidad en % del total de datos utilizado para testing, por default = 20
- val**: Cantidad en % del total de datos utilizados como validación, por default = 10
- fa**: Función de activación, puede ser *tangente*, *tangente_optimizada* o *logística*, por default es *tangente*.

-dp: Distribución de inicialización de pesos a utilizar, puede ser *normal* o *uniforme*, por default se usa *normal*.

-rda: Permite cargar una red entrenada desde un archivo con formato *json*.

2. Desarrollo

2.1. Decisiones tomadas y su justificación.

En esta sección incluiremos los resultados de la experimentación que realizamos con el perceptrón desarrollado.

La idea general de los experimentos es intentar medir la influencia de alguna(s) variable(s) específicas sobre la performance de la red. Para ello intentamos fijar todas las demás variables en valores óptimos y poner a prueba las que nos interesaban.

A medida que fuimos encontrando valores óptimos para las distintas variables, los fuimos utilizando para el resto de los experimentos subsiguientes.

En el primer experimento, intentamos determinar el mejor número de capas ocultas para utilizar en el ejercicio 1. A continuación, los resultados.

2.2. Ejercicio 1

2.2.1. Variación del número de capas ocultas.

La idea de este experimento es determinar la cantidad de capas ocultas óptimas para el ejercicio 1. Para ello fijamos las demás variables con esta configuración:

- Épocas: 250
- ETA: 0.05
- 70 % del dataset como training, 20 % training, 10 % validación.
- Distribución de Pesos: Normal
- Batch Estocástico
- Sin Momentum
- Sin Early Stopping

Esta configuración es arbitraria y está basada en pruebas informales que realizó el equipo antes de comenzar la experimentación formal. A medida que avanzaron los experimentos y fuimos descubriendo mejores valores, los fuimos actualizando para las siguientes pruebas.

El experimento fue desarrollado así:

- Dividimos el dataset en datos de entrenamiento, validación y testing. Utilizamos la misma división para todas las ejecuciones.
- Con la configuración mencionada, corrimos 8 rondas de cada número de capas ocultas utilizando: 1, 2, 3, 5 y 10 capas. Es decir, primero se ejecutaron 8 veces el entrenamiento, validación y testing de una red con 1 capa. Luego repetimos con 2, con 3, etc.
- Para cada cantidad de capas, promediamos los resultados de cada una de las 8 rondas. Con ello obtuvimos un error final (función de costo) de entrenamiento promedio, un error de validación promedio y una efectividad de testing promedio. Llamamos efectividad de testing a la cantidad de resultados del dataset de testing correctamente predichos.
- El error final de cada ronda corresponde a la función de costo de dicha corrida dividido la cantidad de patrones procesados.

Observemos los resultados:

2.2.2. Variación del número de neuronas ocultas.

Una vez obtenido el número óptimo de capas ocultas, quisimos determinar cual era la cantidad de neuronas que debía contener cada una de estas capas. Para simplificar el problema, decidimos que todas las capas tuvieran la misma cantidad de neuronas.

De esta forma, elegimos las siguientes medidas: capas de 2, 5, 7, 10, 15 y 20 neuronas. Estas medidas fueron elegidas para intentar representar una cantidad baja de neuronas como 2,5,7 y otras más altas, por arriba de 10. No consideramos cantidades mayores de neuronas ya que los resultados no mejoran ostensiblemente pasando las 20 neuronas, teniendo en cuenta la relativa sencillez del ejercicio en cuestión. Además, arquitecturas con más de 20 neuronas por capa afectan notablemente la velocidad de ejecución de la red, relentizando las pruebas y haciéndolas engorrosas e innecesarias.

De forma similar al experimento anterior, esta prueba consistió en procesar el dataset completo 8 veces con cada cantidad de neuronas distintas, promediar los errores finales de entrenamiento y de validación junto con la eficiencia obtenida en los datos de testing.

Para el error final, obtuvimos los siguientes resultados:




Figura 1: Error final (función de costo) promedio para cada cantidad de neuronas utilizando el dataset de entrenamiento

En la figura 1 se puede observar que el valor de la función de costo decrece a medida que la cantidad de neuronas crece. Este efecto se vuelve mucho menos notable a partir de las 10 neuronas por capa.

Para el error final, obtuvimos los siguientes resultados:

En la figura 2 podemos notar que el valor de error con el dataset de validación también decrece a medida que sube la cantidad de neuronas, aunque no de forma uniforme. Podemos apreciar que a partir de las 10 neuronas, el error se mantiene por debajo de 0.15.

Para la efectividad en la predicción de los datos de testing, observamos:

Nuevamente podemos apreciar en la figura 3, que a medida que crece la cantidad de neuronas, crece la cantidad de aciertos sobre el conjunto de datos de test. Sin embargo, los resultados se comienzan a estancar a partir de las 10 neuronas en valores cercanos al 90 % de aciertos.

Observando los resultados obtenidos en las pruebas, decidimos que la mejor configuración es con 10 neuronas por capa. Esta decisión se justifica teniendo en cuenta que los resultados no mejoran demasiado pasando de 10 y si empeora notablemente la velocidad de la red.

Por ende, en vistas a los buenos resultados obtenidos con 10 neuronas y no obteniendo mejoras sustanciales con cantidades mayores, nos quedaremos con este valor.




Figura 2: Error (función de costo) promedio para cada cantidad de neuronas utilizando el dataset de validación




Figura 3: Tasa de predicciones correctas, en porcentaje, para el dataset de testing

- 2.2.3. Performance de la red, con entrenamiento sin momentum y con momentum.
- 2.2.4. Performance de la red, con entrenamiento sin y con parámetros adaptativos.
- 2.2.5. Performance de la red, con entrenamiento estocástico, batch y mini-batch.
- 2.2.6. Performance de la red, variando simultáneamente el factor de aprendizaje μ , y el parámetro α del momentum.
- 2.2.7. Performance de la red, con distintas técnicas de inicialización de los pesos de la red.
- 2.2.8. Performance de la red, sin y con preprocesamiento de los patrones.
- 2.2.9. Performance de la red, sin y con early-stopping.
- 2.2.10. Performance de la red, variando las funciones de activación y/o sus parámetros.
- 2.3. Descripción, justificación y performance, de la solución óptima propuesta.
- 2.4. Conclusiones.

3. Apéndice - Código

4. Bibliografía

Referencias

- [1] ANSI C Yacc grammar - Jeff Lee
<https://www.lysator.liu.se/c/ANSI-C-grammar-y.html>